UNIVERSIDAD AUTÓNOMA DE ENTRE RÍOS.

Facultad de Ciencia y Tecnología.

Licenciatura en Sistemas de Información.

Cátedra: Inteligencia Artificial.

Trabajo Práctico: Keras (CNN-RNN)

Docentes:

Mg. Díaz, Santiago R.

Anl. López, Joaquín.

BioIng. Hadad, A.

Alumnos:

Carrere Lautaro - carrerelautaro@gmail.com (45336940)

Demartin Fabricio - fabridemartin@gmail.com (45946470)

Fecha de entrega: 30 de septiembre.

Año lectivo: 2026.

Introducción.

CNN: clasificación de lesiones cutáneas en 7 clases (akiec, bcc, bkl, df, mel, nv, vasc) sobre el dataset HAM10000 (10 015 dermatoscopías, 96×96×3, normalizadas a [0, 1]). Como dificultades, encontramos con que el dataset es muy desbalanceado (nv ≈ 67 %, df ≈ 1 %) y contiene varias imágenes de una misma lesión (lesion_id).

RNN: pronóstico multivariado de la temperatura T (degC) a +24 h a partir de una ventana de 72 h sobre el dataset Jena Climate 2009–2016 (registros cada 10 min submuestreados a 1 h). Se usan 19 variables: 11 meteorológicas, el

viento convertido a vector (wx, wy, max wx, max wy) y codificación cíclica seno/coseno de la hora del día y del día del año.

Módulo CNN.

Arquitectura.

Convolución, padding y stride: En las convoluciones usamos k=3, s=1 y padding="same" (p=1), por lo que se mantienen el alto y el ancho del mapa (o = i). Así también se conservan las posiciones cercanas al borde, aunque parte del contexto proviene del padding. Después, cada pooling de k=2, s=2 reduce la resolución a la mitad: 96 -> 48 -> 24 -> 12.

Campo receptivo: En nuestra arquitectura el campo receptivo crece así: 3 -> 5 -> 6 -> 10 -> 14 -> 16 -> 24 -> 32 -> 36 px. Cada activación final reúne información de una región de 36 píxeles. Esta escala permite combinar detalles locales de la lesión; después, Global Average Pooling resume la información de todas las posiciones.

Pooling y equivarianza: Si se desplaza la imagen, la convolución desplaza también sus mapas de características. MaxPool añade cierta tolerancia a desplazamientos pequeños: a veces el máximo de una ventana se mantiene. Además, al reducir la resolución, disminuye el costo de las capas posteriores. En la cabeza de la red usamos Global Average Pooling (GAP) en lugar de Flatten: así pasamos de 12·12·128·7 = 129 024 parámetros a 903 y reducimos la dependencia de la posición exacta de las características.

Activaciones y estabilidad del gradiente: En las capas ocultas usamos ReLU. En su zona activa, su derivada es 1, por lo que no atenúa el gradiente como pueden hacerlo otras activaciones saturantes. La acompañamos con la inicialización He (Var(W) = 2/n_in), pensada para conservar la escala de las activaciones al usar ReLU. BatchNormalization normaliza las activaciones de cada canal durante el entrenamiento y ayuda a que su distribución sea más estable entre pasos. En la salida, softmax transforma los logits en probabilidades para las 7 clases. Al combinarla con la entropía cruzada categórica, se obtiene el objetivo de máxima verosimilitud y un gradiente respecto de los logits.

Regularización: Para reducir el sobreajuste, aplicamos Dropout de 0.5 antes de la salida y penalización a los núcleos convolucionales. También usamos aumentación geométrica, ya que las imágenes dermatoscópicas no tienen una orientación canónica, y EarlyStopping para detener el entrenamiento cuando deja de mejorar la validación.

Hiperparametros.

Optimizador: Adam, 5e-4. Reducido desde 1e-3 (primera iteración) para amortiguar la oscilación de la validación junto con BN.

Scheduler: ReduceLROnPlateau (×0.5, paciencia 5, mín. 1e-6). Afina el mínimo cuando la validación se estanca.

Batch size: 32. Compromiso entre memoria y ruido estocástico útil para BN.

Épocas: máx. 60; EarlyStopping (paciencia 10, restaura mejores pesos). Épocas ejecutadas: 60/35/34/25/34; mejor época media: 28.8.

Filtros: (32, 64, 128). Se duplican al reducir la resolución a la mitad (costo por bloque ≈ constante).

Desbalance: class_weight="balanced" se calcula solo con el train de cada fold. Pesos de 0.21 (nv) a ≈ 12 (df); usar todo el dataset filtraría la distribución de validación.

Partición sin fuga de información.

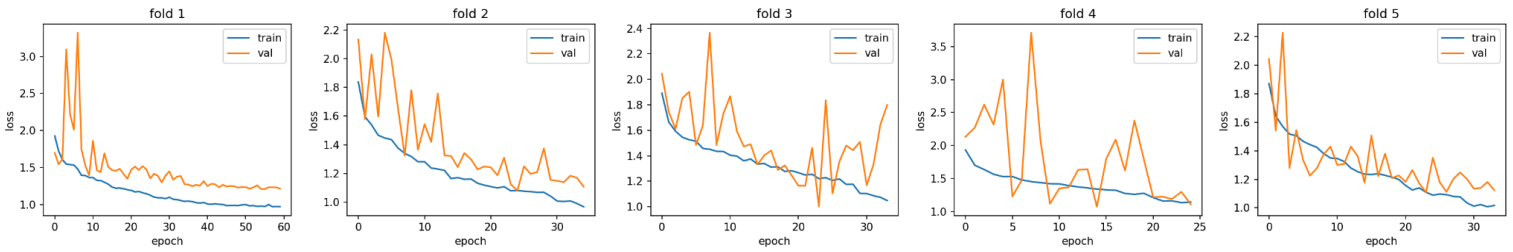
Una partición aleatoria pondría imágenes de la misma lesión en train y validación, y la red podría "memorizar" la lesión (color de piel, vello, reglas o marcas del dermatoscopio) en lugar de aprender la clase. Por eso: (1) GroupShuffleSplit separa un holdout de test del 15 % por lesion_id (8 488 imágenes de desarrollo / 1 527 de test); (2) sobre desarrollo se aplica StratifiedGroupKFold (k = 5), que mantiene cada lesión en un solo fold y preserva la proporción de clases; (3) un assert verifica en ejecución que los grupos de train y validación sean disjuntos. El test se evalúa una sola vez, promediando las probabilidades de los 5 modelos de fold (ensemble), de modo que nunca se usa para elegir entre ellos.

Resultados.

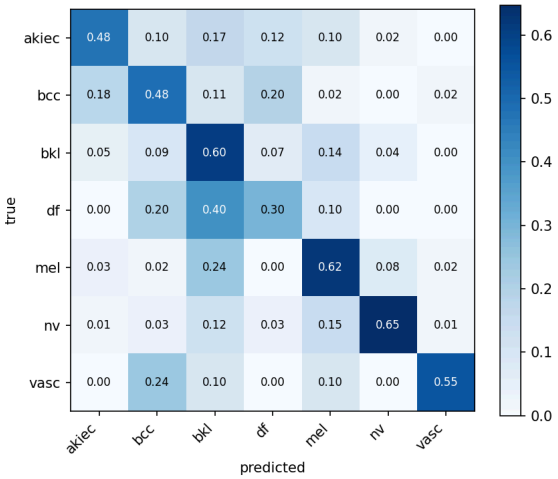
Por el desbalance, accuracy no es informativa (predecir siempre nv da 67 %): se reportan balanced accuracy (es decir, la media de los recalls), F1 macro, ROC-AUC one-vs-rest y el recall de melanoma, la clase clínicamente crítica.

Partición	Balanced acc	F1 macro	ROC-AUC (OvR)	Recall mel
Fold 1	0.601	0.466	0.898	0.554
Fold 2	0.449	0.385	0.871	0.414
Fold 3	0.558	0.479	0.887	0.753
Fold 4	0.410	0.346	0.885	0.594
Fold 5	0.468	0.400	0.856	0.442
CV: media + σ	0.497 +- 0.071	0.415 +- 0.050	0.880 +- 0.015	0.551 +- 0.121
Test holdout	0.527	0.451	0.898	0.618

Perdida de entrenamiento y validación por fold:



Matriz de confusión normalizada por fila en el test holdout.



Análisis de sesgo y varianza.

Generalización y ausencia de fuga: La métrica de test (0.527) cae dentro del intervalo de CV (0.497 ± 0.071) y el AUC coincide (0.898 vs 0.880). Si la red memorizara artefactos visuales de lesiones repetidas, el rendimiento sobre lesiones nunca vistas sería claramente inferior al de CV; no ocurre.

Sesgo (underfitting) dominante. En la mejor época, la accuracy de train (0.52–0.62) es similar a la de validación (0.56–0.63) y la pérdida de train sigue bajando lentamente (≈ 1.0 al final). La red no llega a ajustar bien ni siquiera el entrenamiento: el error es principalmente de sesgo, atribuible a la baja resolución (96×96 pierde detalle de textura) y a la capacidad moderada (≈ 290 k parámetros). La pérdida de train aparece a veces por encima de la de validación porque se calcula con aumentación, dropout, penalización L2 y pesos de clase, que la inflan; la de validación no los incluye.

Varianza baja en el modelo, alta en las clases minoritarias. No hay brecha creciente train–val (sin overfitting sostenido): EarlyStopping corta 10 épocas después del mínimo y restaura los pesos. La validación es ruidosa, con picos en las primeras épocas (fold 4: 3.7) por la actualización de las estadísticas de BN con LR alto y por la escasez de muestras minoritarias (≈ 20/30 imágenes de df o vasc por fold). Esa escasez explica la varianza entre folds: σ del recall bcc = 0.23 (0.00 en el fold 4, 0.67 en el 5) frente a σ = 0.03 en bkl. El AUC, que mide la capacidad de ordenar y no depende del umbral de argmax, es estable (σ = 0.015): la representación aprendida es consistente y lo que varía es la frontera de decisión en las clases raras.

Errores sistemáticos. La matriz muestra confusiones clínicamente plausibles entre clases pigmentadas: mel -> bkl (24 %), df -> bkl (40 %) y nv -> mel (15 %). Por los pesos de clase, el recall de nv baja a 0.65 a cambio de detectar el 62 % de los melanomas, un intercambio deseable en un contexto de tamizaje.

Módulo RNN.

Elección de la celda y BPTT.

Para trabajar con ventanas de 72 pasos, comparamos dos tipos de celda recurrente: GRU y LSTM. Durante el entrenamiento, BPTT propaga el error hacia atrás a través de la

secuencia para ajustar los pesos. Ambas celdas usan compuertas que ayudan a conservar la información relevante durante ese proceso. La elección final se dejó en manos de los resultados de evaluación.

Además, entrenamos tres modelos para predecir el mismo valor a partir de ventanas de 72 pasos y 19 variables: una red densa, una GRU y una LSTM. La red densa sirvió como referencia; la GRU y la LSTM, en cambio, procesan la secuencia paso a paso y pueden mantener información de momentos anteriores. De esta forma, pudimos comparar el rendimiento de las tres alternativas.

Split cronológico y normalización

El split es estrictamente cronológico, sin mezclar: 70 % train (ene 2009 – ago 2014) / 20 % validación (ago 2014 – mar 2016) / 10 % test (mar – dic 2016). La media y el desvío de normalización se ajustan solo con train y se guardan en models/rnn_norm.json para la inferencia. Las ventanas se generan dentro de cada partición, así que ninguna cruza una frontera: el target de cada ventana es T en la posición 72 + 24 − 1, y se verifica la alineación de los timestamps. Solo se mezclan las ventanas del conjunto de train entre sí, lo que no filtra información del futuro porque cada ventana es un par (pasado -> futuro) autocontenido.

Hiperparametros.

Optimizador: Adam, LR 1e-4, clipnorm=1.0. LR bajo para una convergencia estable del BPTT a 72 pasos; el clipping evita la explosión.

Pérdida / métrica: MSE final (many-to-one) / MAE. Se minimiza el error del único valor pronosticado; MSE penaliza más los errores grandes (picos de temperatura); MAE se interpreta en °C.

Batch / épocas: 256 / máx. 50, EarlyStopping (paciencia 8). Ventanas muy correlacionadas: un batch grande estabiliza el gradiente.

Ventana / horizonte: 72 h / +24 h. Tres ciclos diarios completos de contexto.

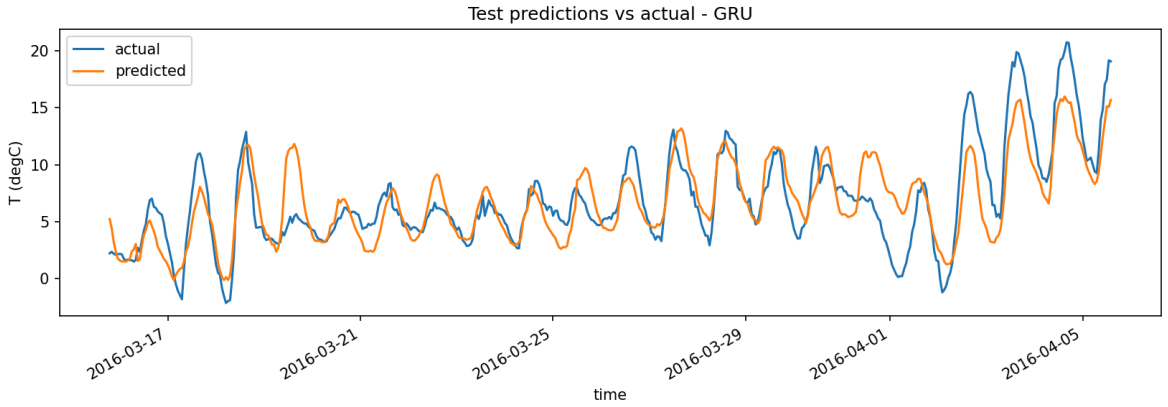
Unidades: (64, 64) + Dense 32. Suficiente para 19 variables con ≈ 43–57 k parámetros.

Resultados.

Modelo	MAE (°C)	RMSE (°C)	Parámetros	Épocas	Tiempo
Persistencia (T(t+24) = T(t))	2.371	3.086	0	-	-
Denso (Flatten → Dense 64 → 1)	2.247	2.842	87 681	32	107 s
LSTM (64, 64)	2.110	2.664	56 641	50	3 004 s
GRU (64, 64)	2.062	2.611	43 393	50	2 755 s

La GRU es el mejor modelo: reduce el MAE un 13.0 % respecto de la persistencia y un 8.2 % respecto del denso, con la mitad de parámetros que este último. La mejora frente al denso, que ve la misma ventana pero aplanada y sin noción de orden, confirma que la recurrencia aprovecha la estructura secuencial.

Predicción a +24 h de la GRU frente al valor real (tramo de test).



Estabilidad predictiva y ajuste.

Curvas de aprendizaje: El denso sobreajusta, MSE de train 0.088 contra 0.145 de validación (normalizado), con una brecha que crece hasta la detención en la época 32. LSTM y GRU no muestran brecha (0.137/0.138 y 0.143/0.133), pero su mejor época fue la 48 y la 50 de 50: todavía mejoraban al alcanzar el límite. El diagnóstico es un leve underfitting por presupuesto de épocas (LR 1e-4) y no por capacidad; aumentar las épocas hubiese mejorado el modelo. La regularización recurrente cumplió su función: no hay varianza excesiva.

Residuos: Son aproximadamente normales, con media −0.19 °C y σ = 2.60 °C: un sesgo sistemático despreciable (ligera sobreestimación).

Estabilidad temporal: El MAE mensual de la GRU oscila entre 1.5 °C (marzo) y 2.5 °C (julio y diciembre), sin deriva a lo largo de los 10 meses de test: el modelo no se degrada al alejarse del período de entrenamiento. El error aumenta en los meses de mayor variabilidad sinóptica. En la figura vemos que la predicción sigue el ciclo diario, pero suaviza los extremos y reacciona con retraso a los cambios bruscos de régimen (frentes, p. ej. 2–5 de abril), información que no está contenida en la ventana pasada de una sola estación.