Clase 28 de mayo de 2026

Redes Neuronales Convolucionales (CNN)

Convolución, procesamiento digital de señales, visión por computadora y diseño de arquitecturas profundas

Inteligencia Artificial · 4.º año · Lic. en Sistemas de Información

Profesores: Mg. Díaz Santiago R. · AS. López Joaquín · BioIng. Hadad Alejandro

Objetivo: que el alumno pueda leer la arquitectura, entender la matemática y reconocer los supuestos del modelo.

ESTRUCTURA

Mapa de la clase

1. **Motivación: de MLP a visión artificial**
2. **Señales discretas e imágenes 2D**
3. **Convolución: definición y propiedades**
4. **Capas convolucionales y backpropagation**
5. **Arquitecturas CNN y caso “encapuchado”**
6. **Evaluación, errores y buenas prácticas**

¿Por qué no alcanza una red multicapa densa para imágenes?

Problema de escala

- Una imagen 224×224×3 tiene 150.528 entradas.
- Una capa densa de 1.000 neuronas tendría más de 150 millones de pesos.
- El modelo ignora que píxeles cercanos tienen relación local.

Idea central de CNN

- Usar conectividad local: mirar vecindades pequeñas.
- Compartir pesos: el mismo detector se aplica en toda la imagen.
- Construir jerarquías: bordes → texturas → partes → objetos.

Imagen como señal discreta bidimensional

$$X : \{0, \ldots, H-1\} \times \{0, \ldots, W-1\} \to \mathbb{R}^C$$

Interpretación

Una imagen digital no es una “foto” para el modelo: es una función discreta definida sobre una grilla. La red aprende transformaciones sobre esa función.

Qué significa cada símbolo

- X(i,j,c): intensidad del canal c en la posición espacial (i,j).
- H: alto de la imagen; W: ancho; C: cantidad de canales.
- Para RGB, C=3; para escala de grises, C=1.

Ejemplo de uso

Si X(10,20,1)=180, significa que el canal verde en el píxel (10,20) tiene intensidad 180.

Convolución 1D en procesamiento digital de señales

$$(x * h)[n] = \sum_{k=-\infty}^{\infty} x[k]h[n-k]$$

Interpretación

En DSP, la convolución describe cómo un sistema lineal e invariante en el tiempo modifica una señal. En CNN, la idea se traslada a grillas espaciales.

Qué significa cada símbolo

- x[k]: señal de entrada discreta.
- h[k]: respuesta impulsional o filtro.
- n: posición temporal donde calculamos la salida.
- La suma pondera valores de x con una versión invertida/desplazada de h.

Ejemplo de uso

Un filtro de suavizado puede promediar muestras cercanas para reducir ruido en audio, sensores o imágenes.

TEOREMA / PROPIEDAD

Propiedad de sistemas LTI: salida por convolución

Enunciado

Si un sistema discreto es lineal e invariante ante desplazamientos, su salida queda determinada por la convolución entre la entrada y la respuesta al impulso.

Supuestos

- Linealidad: $T(ax+bz)=aT(x)+bT(z)$.
- Invarianza: desplazar la entrada desplaza la salida.
- La respuesta al impulso h caracteriza completamente al sistema.

Consecuencia práctica

- La CNN reutiliza filtros locales como detectores de patrones.
- Los kernels funcionan como respuestas aprendidas, no fijadas manualmente.
- Esto explica la eficiencia de las CNN frente a capas densas.

Convolución 2D discreta

$$Y[i,j] = \sum_{u=-r}^{r} \sum_{v=-s}^{s} X[i-u, j-v] K[u,v]$$

Interpretación

La salida en cada píxel se calcula combinando una vecindad de la entrada. Si el patrón local se parece al kernel, la activación aumenta.

Qué significa cada símbolo

- X: imagen o mapa de entrada.
- K: kernel o filtro de tamaño (2r+1)×(2s+1).
- Y[i,j]: respuesta del filtro en la posición (i,j).
- u,v: índices locales dentro de la ventana.

Ejemplo de uso

Un kernel de borde vertical activa zonas donde cambia fuertemente la intensidad de izquierda a derecha.

Correlación cruzada: lo que implementan muchas librerías

$$Y[i,j] = \sum_u \sum_v X[i+u, j+v] K[u,v]$$

Interpretación

PyTorch y TensorFlow suelen implementar correlación cruzada. En práctica, la red aprende el kernel que necesita.

Qué significa cada símbolo

- A diferencia de la convolución estricta, no invierte el kernel.
- En deep learning se llama “convolución” por convención.
- Como K se aprende, invertir o no invertir no cambia la capacidad del modelo.

Ejemplo de uso

Cuando se entrena desde cero, el optimizador ajusta K para maximizar desempeño, sin importar la convención de signo/desplazamiento.

Convolución 2D: ejemplo numérico paso a paso

Imagen discreta X y kernel K

2	1	0	0
1	3	2	1
0	1	2	3
1	0	1	2

1	0
-1	1

Cálculo en la esquina superior izquierda

$$Y_{1,1} = 2 \cdot 1 + 1 \cdot 0 + 1 \cdot (-1) + 3 \cdot 1 = 4$$

Qué aprende una CNN

- El kernel no se define a mano en entrenamiento supervisado.
- Los valores de K son pesos ajustados por backpropagation.
- Al inicio K detecta patrones débiles; luego se especializa en bordes, texturas o partes.

- La convolución combina vecindades locales.
- El mismo kernel se reutiliza en toda la imagen: pesos compartidos.
- El resultado Y es un mapa de activación: dónde aparece el patrón.

Tamaño de salida: stride, padding y kernel

$$H_{out} = \left\lfloor \frac{H + 2P - K}{S} \right\rfloor + 1$$

Interpretación

Esta fórmula decide cuántas posiciones alcanza a visitar el kernel. Controla resolución espacial y costo computacional.

Qué significa cada símbolo

- H: tamaño de entrada en una dimensión.
- P: padding agregado en cada borde.
- K: tamaño del kernel.
- S: stride o salto de la ventana.
- ⌊·⌋: parte entera inferior.

Ejemplo de uso

Con H=32, K=3, P=1, S=1 resulta H_out=32: se preserva la resolución espacial.

Stride, padding y dilatación

Stride

- S=1 analiza cada posición.
- S>1 reduce resolución y costo.
- Un stride grande puede perder detalles pequeños.

Padding y dilatación

- Padding preserva bordes y tamaño espacial.
- Dilatación separa elementos del kernel para ampliar campo receptivo.
- La elección depende del patrón esperado y de la escala del objeto.

Convolución multicanal

$$Y_m[i,j] = b_m + \sum_{c=1}^{C_{in}} \sum_{u} \sum_{v} X_c[i+u, j+v] K_{m,c}[u,v]$$

Interpretación

Cada filtro combina todos los canales de entrada y produce un mapa. Con M filtros se obtienen M mapas: el volumen se transforma de C_in a M canales.

Qué significa cada símbolo

- m: índice del filtro de salida.
- C_in: cantidad de canales de entrada.
- K_{m,c}: kernel del filtro m aplicado al canal c.
- b_m: bias del mapa de salida m.
- Y_m: mapa de activación m.

Ejemplo de uso

En una imagen RGB, un filtro puede combinar color, contraste y textura para activar zonas de tela oscura o contornos.

Cantidad de parámetros de una capa convolucional

$$\#\theta = (K_h K_w C_{in} + 1) C_{out}$$

Interpretación

La gran ventaja es que el número de parámetros no depende directamente de H ni W, sino del tamaño del kernel y de los canales.

Qué significa cada símbolo

- K_h,K_w: alto y ancho del kernel.
- C_in: canales de entrada.
- C_out: filtros o canales de salida.
- +1: bias por filtro.
- θ: conjunto de parámetros entrenables.

Ejemplo de uso

Con K=3×3, C_in=64 y C_out=128: parámetros=(3·3·64+1)·128=73.856.

TEOREMA / PROPIEDAD

Equivarianza traslacional de la convolución

Enunciado

Si T_a desplaza la entrada y $*$ denota convolución, entonces bajo condiciones discretas adecuadas: $T_a(X)*K = T_a(X*K)$.

Supuestos

- El mismo kernel se aplica en todas las posiciones.
- La operación respeta desplazamientos de la señal.
- Padding y bordes pueden introducir excepciones locales.

Consecuencia práctica

- Si un borde aparece más a la derecha, la activación aparece más a la derecha.
- Esto permite reconocer patrones sin aprender un detector por cada posición.
- Pooling y augmentations ayudan a lograr invariancia aproximada.

Pooling máximo y promedio

$$Y[i,j] = \max_{(u,v)\in\Omega_{i,j}} X[u,v] \quad \text{o} \quad Y[i,j] = \frac{1}{|\Omega|} \sum_{(u,v)\in\Omega_{i,j}} X[u,v]$$

Interpretación

Pooling reduce resolución y aporta robustez a pequeños desplazamientos, pero también puede descartar información fina.

Qué significa cada símbolo

- Ω_{i,j}: ventana local asociada a la salida (i,j).
- Max pooling conserva la activación más fuerte.
- Average pooling resume intensidad media.
- |Ω|: cantidad de elementos de la ventana.

Ejemplo de uso

Para detectar una capucha, puede importar que el borde curvo exista cerca de una zona, no su píxel exacto.

Activación ReLU en CNN

$$\mathrm{ReLU}(z) = \max(0, z)$$

Interpretación

Sin funciones de activación, muchas capas convolucionales serían equivalentes a una sola transformación lineal. ReLU permite aprender fronteras complejas.

Qué significa cada símbolo

- z: preactivación generada por convolución + bias.
- Si z>0, la señal pasa sin cambiar.
- Si z≤0, se anula.
- Introduce no linealidad capa a capa.

Ejemplo de uso

Un detector puede activarse sólo cuando una combinación de borde, textura y contraste supera cierto umbral.

Batch Normalization en mapas convolucionales

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}, \qquad y = \gamma \hat{x} + \beta$$

Interpretación

Normalizar estabiliza la distribución interna de activaciones, permite tasas de aprendizaje mayores y reduce sensibilidad a inicialización.

Qué significa cada símbolo

- μ_B, σ_B²: media y varianza del mini-batch.
- ε: constante pequeña para estabilidad numérica.
- γ, β: parámetros aprendibles de escala y desplazamiento.
- y: activación normalizada reescalada.

Ejemplo de uso

En visión, BN suele aplicarse entre convolución y activación: Conv → BN → ReLU.

Bloque convolucional básico



- Un bloque no “ve” toda la imagen: detecta patrones locales.
- Al apilar bloques, el campo receptivo crece y aparecen representaciones semánticas.
- El diseño combina precisión, costo y escala del objeto.

Campo receptivo efectivo

$$R_l = R_{l-1} + (K_l - 1) \prod_{q=1}^{l-1} S_q$$

Interpretación

El campo receptivo indica qué región de la imagen original puede influir sobre una activación profunda.

Qué significa cada símbolo

- R_l: campo receptivo de la capa l.
- K_l: tamaño del kernel en la capa l.
- S_q: stride de la capa q.
- R_0=1 para un píxel de entrada.

Ejemplo de uso

Para reconocer una persona encapuchada, la red necesita relacionar cabeza, hombros, contexto y textura de ropa: no alcanza un píxel.

Jerarquía de características

Capas tempranas

- Bordes horizontales, verticales y diagonales.
- Cambios de color y contraste.
- Texturas simples y esquinas.

Capas profundas

- Partes de objetos: rostro, hombros, capucha, manos.
- Configuraciones espaciales más abstractas.
- Representaciones útiles para clasificación, detección o segmentación.

Arquitectura para clasificación de imágenes



- El backbone extrae características; la cabeza toma la decisión final.
- Global Average Pooling reemplaza muchas capas densas y reduce sobreajuste.
- Softmax produce una distribución de probabilidad entre clases.

Softmax para clasificación multiclase

$$p(y = k \mid x) = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}$$

Interpretación

Softmax convierte puntuaciones arbitrarias en probabilidades comparables. No garantiza calibración perfecta: una probabilidad alta puede estar mal calibrada.

Qué significa cada símbolo

- z_k: logit de la clase k.
- K: número total de clases.
- p(y=k|x): probabilidad estimada por el modelo.
- La suma de probabilidades sobre clases es 1.

Ejemplo de uso

Clases posibles: “encapuchado”, “no encapuchado”, “indeterminado”.

Pérdida de entropía cruzada

$$\mathcal{L}(\theta) = -\sum_{k=1}^{K} y_k \log \hat{p}_k$$

Interpretación

Minimizar entropía cruzada aproxima máxima verosimilitud bajo una distribución categórica.

Qué significa cada símbolo

- θ: parámetros de la CNN.
- y_k: etiqueta real codificada one-hot.
- p̂_k: probabilidad predicha para clase k.
- La pérdida penaliza asignar baja probabilidad a la clase correcta.

Ejemplo de uso

Si la clase real es “encapuchado” y p̂=0,20, la pérdida será alta; si p̂=0,95, será baja.

Backpropagation: gradiente del kernel

$$\frac{\partial \mathcal{L}}{\partial K[u,v]} = \sum_{i,j} \frac{\partial \mathcal{L}}{\partial Y[i,j]} X[i+u, j+v]$$

Interpretación

El gradiente de un kernel compartido se acumula en todas las ventanas. Por eso un solo peso recibe señal de muchos lugares de la imagen.

Qué significa cada símbolo

- L: función de pérdida total.
- K[u,v]: peso del kernel en posición local (u,v).
- Y[i,j]: salida de la convolución.
- La suma acumula aportes de todas las posiciones donde se reutilizó el peso.

Ejemplo de uso

Si un borde de capucha aparece en distintas posiciones, todas esas evidencias modifican el mismo detector.

Descenso por gradiente en CNN

$$K^{(t+1)} = K^{(t)} - \eta \frac{\partial \mathcal{L}}{\partial K}$$

Interpretación

El entrenamiento ajusta filtros para que activen patrones útiles y reduzcan errores de clasificación.

Qué significa cada símbolo

- K^{(t)}: kernel antes de la actualización.
- η: tasa de aprendizaje.
- ∂L/∂K: dirección de mayor aumento de pérdida.
- El signo menos mueve los parámetros para reducir L.

Ejemplo de uso

Un kernel inicialmente aleatorio puede convertirse en detector de borde curvo si eso reduce la pérdida.

Caso real: identificación de una persona encapuchada

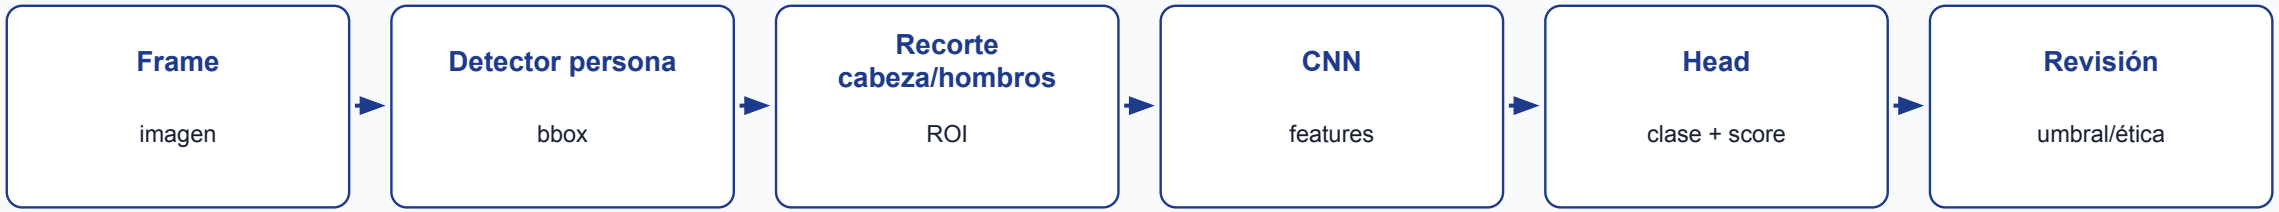
Planteo del problema

• Puede formularse como clasificación, detección u segmentación.
• La etiqueta debe estar definida con precisión: capucha puesta, gorro, casco, sombra.
• Debe incluir clase “indeterminado” cuando la evidencia visual es insuficiente.

Riesgos técnicos

• Iluminación, cámaras de baja calidad, oclusión y movimiento.
• Confusión con pelo, bufandas, cascos o mochilas.
• Sesgos por contexto: noche, ropa oscura o ubicación no deben reemplazar la evidencia visual.

Pipeline CNN para el caso “encapuchado”



- Primero se localiza la persona; luego se clasifica la región relevante.
- La red debe aprender evidencia visual de capucha, no proxies contextuales.
- En entornos sensibles conviene usar revisión humana y umbrales conservadores.

Datos para el ejemplo “encapuchado”

Diseño del dataset

- Diversidad de cámaras, iluminación, ángulos y distancias.
- Balance entre capucha, no capucha e indeterminado.
- Etiquetado con guía explícita para reducir ambigüedad.

División correcta

- Separar por video/cámara/escena, no sólo por frames aleatorios.
- Evitar que frames casi idénticos estén en train y test.
- Test final debe simular cámaras no vistas.

Matriz de confusión binaria

$$\begin{pmatrix} TP & FP \\ FN & TN \end{pmatrix}$$

Interpretación

La matriz de confusión permite ver tipos de error, no sólo exactitud global.

Qué significa cada símbolo

- TP: encapuchado correctamente detectado.
- FP: no encapuchado marcado como encapuchado.
- FN: encapuchado no detectado.
- TN: no encapuchado correctamente descartado.

Ejemplo de uso

Un FP puede generar alarma indebida; un FN puede perder un caso relevante. El costo de error depende del contexto.

Precisión, recall y F1

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN}, \quad F1 = 2\frac{PR}{P + R}$$

Interpretación

La métrica correcta depende del costo relativo de FP y FN. En vigilancia, no se debe optimizar sólo accuracy.

Qué significa cada símbolo

- Precision: de los positivos predichos, cuántos eran correctos.
- Recall: de los positivos reales, cuántos detectó el modelo.
- F1: media armónica entre precisión y recall.
- P y R abrevían precision y recall.

Ejemplo de uso

Si hay pocos encapuchados, un modelo que siempre dice “no” puede tener alta accuracy y ser inútil.

ROC y área bajo la curva

$$AUC = \int_0^1 TPR(FPR)\, dFPR$$

Interpretación

ROC evalúa la capacidad de ordenar positivos por encima de negativos. No fija un umbral operativo.

Qué significa cada símbolo

- TPR: tasa de verdaderos positivos = recall.
- FPR: tasa de falsos positivos = FP/(FP+TN).
- AUC resume desempeño al variar el umbral.
- La integral representa el área bajo la curva ROC.

Ejemplo de uso

Un sistema puede tener AUC alto pero requerir un umbral distinto si el costo de falsas alarmas es alto.

Underfitting y overfitting en CNN

Underfitting

- Modelo demasiado simple o entrenamiento insuficiente.
- Error alto en train y validación.
- La red no aprende filtros útiles.

Overfitting

- Error bajo en train pero alto en validación/test.
- Memoriza cámaras, fondos o iluminación.
- Se mitiga con augmentations, regularización, más datos y validación por escena.

Regularización L2

$$\mathcal{L}_{reg} = \mathcal{L}_{data} + \lambda \|\theta\|_2^2$$

Interpretación

L2 desalienta pesos excesivamente grandes y puede mejorar generalización.

Qué significa cada símbolo

- L_data: pérdida de clasificación.
- λ: intensidad de regularización.
- θ: todos los pesos entrenables.
- ||θ||²: suma de cuadrados de parámetros.

Ejemplo de uso

Si una CNN memoriza texturas de una cámara específica, regularizar puede ayudar, aunque no reemplaza buenos datos.

Aumentación de datos

Transformaciones útiles

- Recortes, cambios de brillo, blur, ruido, pequeñas rotaciones.
- Oclusiones parciales simuladas.
- Balance de clases mediante muestreo cuidadoso.

Cuidado conceptual

- No aplicar transformaciones que cambien la etiqueta.
- No usar augmentations que oculten el sesgo del dataset.
- Validación y test no deben aumentarse como train.

Calibración de probabilidades

$$\hat{p}_{cal} = \text{softmax}\left(\frac{z}{T}\right)$$

Interpretación

Un clasificador puede acertar mucho y estar mal calibrado. La calibración importa si se usan umbrales de decisión.

Qué significa cada símbolo

- z: logits antes de softmax.
- T: temperatura de calibración.
- T>1 suaviza probabilidades; T<1 las vuelve más extremas.
- p̂_cal: probabilidades calibradas.

Ejemplo de uso

Para derivar casos a revisión humana, un score calibrado permite elegir umbrales más justificados.

Análisis de error en CNN

Sesgo estadístico

- Datos de entrenamiento no representan el uso real.
- Etiquetas ambiguas o inconsistentes.
- Atajos: fondo, iluminación, cámara, horario.

Varianza y robustez

- Alta sensibilidad a pequeñas variaciones.
- Resultados inestables por semilla o partición de datos.
- Se analiza por subgrupos, escenarios, cámaras y condiciones de iluminación.

Interpretabilidad: Grad-CAM

Pregunta

- ¿Qué región de la imagen influyó en la predicción?
- ¿La red mira la capucha o mira el fondo?
- ¿La activación coincide con evidencia humana?

Uso académico

- No prueba causalidad, pero ayuda a auditar errores.
- Permite detectar atajos visuales.
- Debe combinarse con métricas cuantitativas y revisión de casos.

Grad-CAM: peso por canal

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

Interpretación

Grad-CAM pondera mapas de activación según su influencia en el score de una clase.

Qué significa cada símbolo

- A^k: mapa de activación k de una capa convolucional.
- y^c: score de la clase c.
- α_k^c: importancia del canal k para la clase c.
- Z: cantidad de posiciones espaciales.

Ejemplo de uso

Si la clase es “encapuchado”, esperamos que el mapa resalte cabeza/hombros, no la vereda o la hora nocturna.

Transfer learning

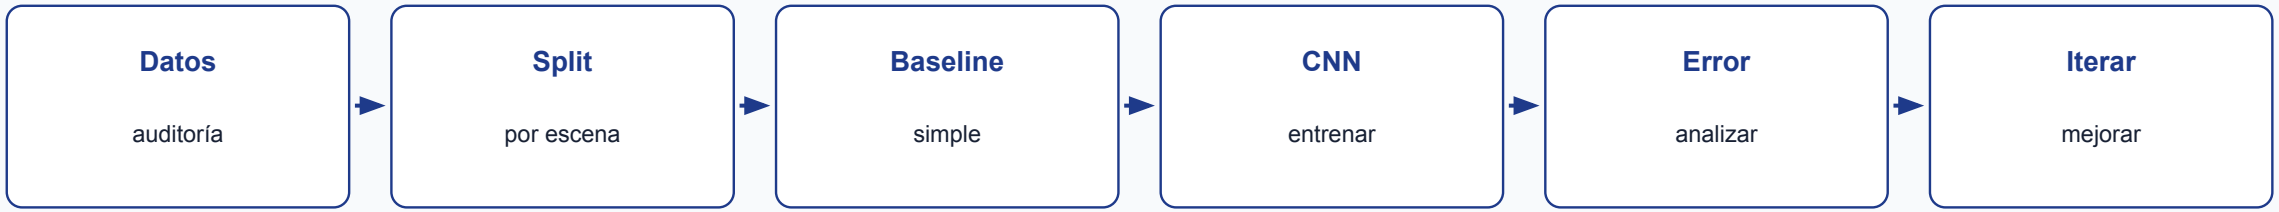
Idea

- Usar una CNN preentrenada como extractor de características.
- Congelar capas iniciales y ajustar la cabeza.
- Luego, opcionalmente, fine-tuning parcial.

Cuándo conviene

- Datasets pequeños o costosos de etiquetar.
- Imágenes naturales similares al preentrenamiento.
- Cuando se necesita buen desempeño inicial con menos datos.

Diseño recomendado de experimento CNN



- No comenzar con la red más grande: primero definir métrica y baseline.
- La comparación justa requiere el mismo split y la misma métrica.
- El análisis de error guía nuevas etiquetas, augmentations y arquitectura.

Validación cruzada estratificada por grupos

$$\hat{E}_{CV} = \frac{1}{K} \sum_{k=1}^{K} E\left(f^{(-k)}, D_k\right)$$

Interpretación

En imágenes correlacionadas, conviene agrupar por escena, paciente, cámara o video para evitar fuga de información.

Qué significa cada símbolo

- K: número de folds.
- D_k: fold de validación k.
- f^{(-k)}: modelo entrenado sin el fold k.
- E: métrica de error elegida.

Ejemplo de uso

Para videos de seguridad, todos los frames de una misma cámara/escena deben quedar en el mismo fold.

Errores frecuentes en proyectos CNN

Errores de datos

- Leakage por frames duplicados en train y test.
- Clases mal definidas o etiqueta “indeterminado” ausente.
- Desbalance extremo no reportado.

Errores de modelado

- Confundir accuracy con utilidad operativa.
- No revisar falsos positivos y falsos negativos.
- No validar robustez ante cámaras no vistas.

Actividad: diseñar una CNN responsable

1. Definir formalmente las clases para el caso “encapuchado” y proponer criterios de etiqueta.
2. Calcular H_out para H=128, K=5, P=2, S=2 e interpretar la pérdida de resolución.
3. Proponer tres augmentations válidas y una inválida, justificando por qué.
4. Diseñar una matriz de confusión y explicar qué error es más costoso en el contexto elegido.
5. Indicar cómo partir train/valid/test para evitar leakage por video.

Resumen conceptual de CNN

Matemática

- Convolución/correlación como operación local y compartida.
- Gradientes acumulados sobre kernels reutilizados.
- Equivarianza traslacional como propiedad clave.

Práctica

- Arquitectura = bloques conv + normalización + activación + pooling.
- Evaluación = métricas, matriz de confusión, ROC/AUC y análisis de error.
- Generalización depende tanto de datos como de modelo.

Bibliografía mínima y lecturas recomendadas

- Goodfellow, Bengio & Courville. Deep Learning. MIT Press.
- LeCun, Bottou, Bengio & Haffner. Gradient-based learning applied to document recognition.
- Krizhevsky, Sutskever & Hinton. ImageNet classification with deep convolutional neural networks.
- He et al. Deep residual learning for image recognition.
- Selvaraju et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization.

Cierre

Lo que el alumno debe poder explicar

- Qué es una convolución y cómo se calcula en 2D.
- Qué significan kernel, stride, padding, pooling, canal y bias.
- Cómo se entrena una CNN mediante backpropagation.

Lo que debe poder criticar

- Si el split de datos es correcto.
- Si las métricas responden al problema real.
- Si el modelo aprende evidencia visual o atajos espurios.

Kernel Sobel: detector de borde vertical

Interpretación

Sobel es una introducción clásica de procesamiento digital de imágenes: muestra cómo un filtro local detecta cambios de intensidad.

Qué significa cada símbolo

- K_x: kernel diseñado manualmente para gradiente horizontal.
- Valores negativos responden a intensidades a la izquierda.
- Valores positivos responden a intensidades a la derecha.
- La CNN aprende kernels análogos, pero optimizados por datos.

Ejemplo de uso

Una CNN temprana puede aprender filtros parecidos a Sobel para activar bordes de capucha, hombros o siluetas.

Normalización de imagen antes de la CNN

$$X'_{i,j,c} = \frac{X_{i,j,c} - \mu_c}{\sigma_c}$$

Interpretación

Normalizar evita que la escala de los píxeles domine el entrenamiento y mejora la estabilidad del gradiente.

Qué significa cada símbolo

- X_{i,j,c}: valor original del píxel.
- μ_c: media del canal c en train.
- σ_c: desvío estándar del canal c en train.
- X’: valor normalizado.

Ejemplo de uso

En RGB se normaliza cada canal con estadísticas calculadas sólo en entrenamiento, no con test.

Clasificación, detección y segmentación

Clasificación

- Entrada: imagen completa o recorte.
- Salida: una clase global.
- Ejemplo: “encapuchado/no encapuchado”.

Detección y segmentación

- Detección: clase + caja delimitadora.
- Segmentación: clase por píxel o máscara.
- Para vigilancia, detectar persona antes de clasificar reduce falsos positivos.

Ejemplo de arquitectura CNN para laboratorio

Backbone sugerido

- Input 128×128×3.
- Conv(32,3×3)+BN+ReLU+MaxPool.
- Conv(64,3×3)+BN+ReLU+MaxPool.
- Conv(128,3×3)+BN+ReLU+GlobalAvgPool.

Cabeza y evaluación

- Dense 64 + Dropout.
- Softmax 3 clases: capucha / no / indeterminado.
- Reportar matriz de confusión, F1 por clase y revisión de FP/FN.